CHECKPOINT – NLP, CHATBOTS E AGENTES VIRTUAIS + RPA

Extração e Análise de Dados Online com Web Scraping, RAG e NLP

1. Contexto do Desafio

No cenário atual de negócios, organizações utilizam grandes volumes de dados disponíveis na internet para compreender a percepção do público, identificar tendências e apoiar a tomada de decisões estratégicas.

Neste checkpoint, os alunos deverão desenvolver uma **solução automatizada capaz de coletar dados da internet, analisá-los utilizando técnicas de Processamento de Linguagem Natural (NLP) e gerar um relatório analítico baseado nesses dados**.

O projeto integra conhecimentos de duas disciplinas:

NLP, Chatbots e Agentes Virtuais

- Processamento de texto
- Análise de sentimentos
- Resumo automático
- Uso de modelos de linguagem
- Conceito de RAG (Retrieval-Augmented Generation)

RPA

- Automação de coleta de dados
- Web scraping
- Execução automatizada de tarefas

O objetivo é aproximar os alunos de um **problema real de análise de dados para suporte à tomada de decisão**.

---

2. Objetivo do Projeto

Desenvolver um **pipeline automatizado** capaz de:

1. Coletar dados textuais da internet
2. Processar e organizar esses dados
3. Aplicar análise de sentimentos
4. Utilizar modelos de linguagem para gerar um resumo analítico
5. Apresentar recomendações baseadas nos dados analisados

---

3. Cenário Proposto

Uma **equipe de marketing de uma empresa fictícia** precisa entender como o público está reagindo a um determinado produto, marca ou tema.

Para isso, foi solicitado que uma equipe de análise de dados desenvolva uma solução capaz de:

- Coletar comentários, notícias ou textos disponíveis na internet
- Identificar o sentimento predominante
- Gerar um **relatório resumido com insights acionáveis**

Os alunos assumirão o papel dessa equipe de análise.

---

4. Desafio Técnico

Os alunos deverão criar uma solução composta por quatro etapas principais:

Etapa 1 – Coleta de dados (Web Scraping)

Extrair dados textuais da internet, como por exemplo:
- comentários
- reviews
- notícias
- posts públicos

Ferramentas possíveis:

- Playwright
- BeautifulSoup
- Requests
- APIs públicas

A coleta deve gerar um **dataset textual**.

Etapa 2 – Preparação dos dados

Os dados coletados devem ser:

- organizados
- limpos
- estruturados

Exemplos de etapas:

- remoção de duplicatas
- normalização de texto
- filtragem de ruído

Etapa 3 – Análise de Sentimentos

Aplicar técnicas de NLP para identificar o sentimento presente nos textos:

- positivo
- negativo
- neutro

Pode-se utilizar:

- modelos pré-treinados
- bibliotecas de NLP
- abordagens baseadas em léxico
- modelos baseados em machine learning

Etapa 4 – Geração de Resumo Analítico (RAG ou LLM)

Utilizar um **modelo de linguagem** para gerar:

- um resumo das informações coletadas
- principais padrões encontrados
- sugestões de ações para a equipe de marketing

Exemplos de análises esperadas:

- principais reclamações
- percepções positivas
- temas recorrentes
- recomendações estratégicas

---

5. Ambiente de Desenvolvimento

Para facilitar a execução do projeto, será utilizado:

Google Colab

Motivos:

- ambiente padronizado
- fácil execução
- evita limitações de hardware dos computadores locais

Todo o código deverá estar organizado em um **notebook executável**.

6. Entregáveis

Cada grupo deverá entregar:

1️⃣ **Código do projeto**

Um notebook no **Google Colab contendo**:

- coleta de dados
- processamento
- análise de sentimentos
- geração de resumo

O código deve estar **comentado e organizado**.

2️⃣ **Relatório Analítico**

Documento contendo:

1. Introdução

- tema analisado
- fonte dos dados

2. Metodologia

- como os dados foram coletados
- ferramentas utilizadas

3. Resultados

Apresentar:

- volume de dados coletados
- distribuição de sentimentos
- exemplos de textos analisados

4. Resumo analítico

Gerado pelo modelo de linguagem.

5. Recomendações

Responder:

Com base nos dados analisados, quais ações a equipe de marketing deveria considerar?

7. Critérios de Avaliação

Os projetos serão avaliados considerando:

Critério	Peso
Qualidade da coleta de dados	20%
Implementação técnica	20%
Aplicação correta de NLP	20%
Qualidade do resumo analítico	20%
Clareza do relatório e organização do código	20%

---

8. Requisitos Técnicos

O projeto deve obrigatoriamente:

- utilizar **Python**
- ser executável no **Google Colab**
- conter **web scraping**
- incluir **análise de sentimentos**
- gerar **resumo analítico usando modelo de linguagem**

---

9. Prazo de Entrega

15 de Março de 2026 ate as 23:59h

---

10. Boas Práticas Recomendadas

- comentar o código
- organizar o notebook em seções
- validar os dados coletados
- evitar scraping de sites que bloqueiam automação
- documentar limitações encontradas

---

11. Resultado Esperado

Ao final do checkpoint, os alunos deverão demonstrar capacidade de:

- coletar dados da internet
- aplicar técnicas de NLP
- utilizar modelos de linguagem para análise
- transformar dados em **insights para tomada de decisão**

Resultado do aprendizado esperado

Este checkpoint busca aproximar o aluno de um cenário real de mercado, no qual **automação, análise de dados e inteligência artificial trabalham de forma integrada para gerar valor para o negócio**.